徐英杰



电话：15600112066 | **邮箱：**1812316597@qq.com | GitHub：https://jerry1993-tech.github.io

求职意向：大模型算法工程师

个人评价

有丰富的大模型算法经验，负责算法团队搭建、技术规划和算法项目落地交付。主导过大模型训练、评测、推理、项目应用落地如各类智能对话系统、领域知识图谱等；有较丰富的传统NLP算法经验如文本分类、实体抽取、语义匹配、文本生成等。业务洞察力强，有较好的业务 sense。熟练掌握 RAG/Agent/大模型微调（LoRA和 RLHF技术）和部署（量化、vLLM等），熟练掌握主流大模型技术框架（LLaMA/Qwen/GLM）。自驱力、学习能力强，工作认真负责，主导过多项从 0-1 项目，具备领导团队资源整合和推动技术落地的能力，有一定的项目和团队管理经验。

工作经历

- **北银金科（北京银行集团）** **大模型算法负责人(P7)** 2023.04-2026.04

· 作为团队管理者/算法专家(**P7**)，负责算法团队搭建与日常管理，工作中与产品/研发/测试同学对齐业务需求，制定项目技术方案，协调分配组内**8**位(**5**算法、**3**工程)同学工作安排。担任组负责人期间组内同学无主动离职现象。

· 负责0到1研发金融大模型、小京财智、金融知识图谱、数聚智库智能问答、智能签退Agent助手等项目。发表 **5** 项专利。

· 年度绩效共参评2次：**1次A（前10%）、1次B（前40%）**，24年荣获团队卓越项目奖。

- **蔚来汽车** **NLP算法**(远程兼职非正式) 2022.09-2023.04

· 肺炎出院养病gap期间的非正式工作，主要参与优化座舱助手NOMI FAQ对话系统、基于用车手册等数据LLM训练工作。

- **知乎（成都研发中心）** **NLP算法工程师(T6)** 2019.07-2022.01

· 作为技术骨干/项目负责人，负责知乎智能客服、社区内容理解，包括但不限于文本分类、实体抽取、语义匹配、文本生成、模型预训练、微调及压缩蒸馏等算法研发。发表 **2** 项专利。

· 年度绩效共参评3次：**1次A+（前10%）、2次A（前30%）**，20年知乎年度最佳新人奖，20、21年评为知乎文化标兵。

- **网易** **推荐算法实习生** 2018.03-2018.09

主要项目经历(倒序)

京科金融大模型（从0-1）- 技术Leader（8人）（体验入口：**https://ai.bobfintech.com.cn/chats**）

项目描述：主导银行业金融大模型全链路研发，打造 7**B**、**14B**、**32B** 等参数系列模型，服务于小京财智、策略复盘 Agent 和数聚智库问答系统等核心业务场景。模型在任务指标和业务落地效果上显著优于同级参数开源模型、部分任务效果优于同代更大参数。

工作职责: 担任项目技术 Leader，主导全链路研发方案设计与训练优化、模型评测、推动业务落地应用。

技术亮点与难点解决：

- 基座增量**预训练**数据处理与训练：
  - 数据构建：整合银行历史问答数据、财报/年报、内部研究分析报告等 **11** 类高密度金融数据。按不同类型对数据解析、清洗去重、质量判优等，Scaling Low确定领域最佳配比，基于Remix 采样、训练总量 **250B**。
  - 数据优化：结合 Qwen 72B 模型评分与训练 MacBERT 小型专家模型判优，构建高质量数据集。
  - **选型与训练优化**：先后基于 Qwen-Series 模型（1.5、2.5、3代），持续验证业界公开预训练技术。采用 DeepSpeed 实现多机多卡并行加速训练；

    设计Channel Loss，针对通用、金融和代码3方向构建在线子集与离线全集验证机制，指导模型训练优化；数据Replay+两阶段8K到16K递进训练策略，提升长文本能力。
- **Post-Training 阶段优化：**
  - 指令数据构建：借鉴 Evol-Instruct 和 Self-Instruct，设计标准化构建与筛选流程，针对金融领域 7 大场景能力、36 个任务，合成50多万条多样高质金融指令数据。
  - **优化对齐训练策略**：尝试 “SFT + DPO” 双循环训练策略，迭代两轮动态加入新数据与高难度偏好数据；GRPO+专家设计Verifier+LLM-as-Judge训练策略提升模型领域长链推理能力。使用prompt mask策略优化loss。
  - RL 数据优化：通过局部对比、否定对比、数字变换对比等构造高质量偏好对齐样本，提升模型对复杂约束任务的响应准确性和任务理解稳定性。闭源模型数据蒸馏+多模型交叉评分/人专家辅助评定筛选优化。
- **自研评测体系：**
  - 知识探针：针对训练数据构建 Few-shot 评测集，测试不同训练阶段的知识记忆与遗忘情况。
  - 专属评测集：基于 C-Eval 和 F-Eval-PPL 金融集评估 CPT 阶段基座模型；Post-Training 阶段基于 F-Eval2.0 主客观题评测。
  - 评测效果：金融32B模型在F-Eval-PPL集上PPL从9.4 降至 5.2，C-Eval 81.4(-2.3)；Post-Training 阶段 F-Eval2.0 客观题正确率从 87.28% 提升至 92.42%，主观题AVG分从 84.26 提升至 91.65；金融场景效果明显优于同代72B模型，整体表现媲美 GPT4o。

项目成果：模型成功应用于小京财智、策略复盘 Agent 和数聚智库问答系统，覆盖北京银行全行业务，显著提升效率**30%**。

小京财智/RAG私域文档问答统一框架（从0-1）- 技术Leader（6人）（体验入口：**https://ai.bobfintech.com.cn/chats**）

项目描述：通过LLM+混合检索技术，构建智能财报助手系统，集成文档上传解析、用户问答、问题推荐、预览定位、问答库缓存等模块，实现指标查询、统计分析、同业对比，个人私域文档问答等功能，为业务人员、管理层决策等提供高效辅助工具。

工作职责：项目技术leader，全链路技术方案设计与优化，对接产品、测试需求。

主要技术点：基于向量检索、SQL数据库检索、全文稀疏检索的混合检索智能财报助手，实现对42家上市银行、8千多家专精特新企业的财报/年报智能查询与分析。私域文档问答统一框架支持个人上传多格式金融文档实时问答与解读总结。

项目亮点与难点解决:

- 文档解析：基于与CV组合作文档解析组件，完成文档结构树、大纲提取、标题回溯、大/小段切分、图片表格识别、有限状态机表格抽取等模块的开发。
- NLU模块：设计问题路由Prompt，训练优化模型多分类效果；设计多类型问题链处理策略，提升系统回复准确性与可解释性。
- **混合检索策略优化**:
  - RAG多路召回：基于文档库构建训练数据微调Embedding模型+BM25稀疏召回，同时在文件名、段落召回基础上，采用LLM增加 doc2query、markdown2doc摘要、FAQ等召回策略，解决提升召回率准确率问题。
  - 数据库字段召回：基于意图要素提取与向量语义的Schema Linking，减少token数，推理提升1.6x、SQL生成准确率提升0.12。
- 模型层优化：
  - **表格问答模型SFT**：针对表格问答任务训练专项京科7B模型，为最大程度保留结构化信息使用Markdown+HTML形式表征表格；微调后表格查询类问题准确率提升0.22。
  - **模型NL2SQL生成优化**：基于LLM与模板驱动合成SQL训练数据12k，微调专项京科7B模型；采用分词和sqlparse校验修正策略降低幻觉生成。
  - **问答大模型SFT**：构造RAG问答训练数据(20w+)，采用RAFT策略微调京科32B-1.0模型；问答效果最终与MiniMax-abab5.5、ZhiPu-Turbo准确率持平，幻觉率降低10个点(13% vs 3%)。
- 引用溯源：针对溯源模型答案中每个子句的参考段落，构造10w+训练数据，微调BERT-Reranker、LLM-Reranker等模型；最终子句Acc提升0.34，F1提升0.33。

项目成果：PC、移动端均上线北京银行总行与17家分行机构，显著提升业务研究人员工作效率、辅助管理层精准决策。

北京银行智能签退Multi-Agent助手（从0-1）- 技术Leader（5人）

项目描述: 银行签退业务依赖人工每天手动操作循环查询和统计各自分行的签退情况、提醒与报备，流程繁琐、效率低下。通过LLM+Agent 技术构建智能签退管理 Multi-Agent 系统，实现签退管理自动化与流程智能化。

工作职责: 担任项目技术 Leader，主导全链路技术方案设计，跨部门对接产品与测试需求。负责/参与 Prompt 设计、Query理解、Tools Schema定义、问数 Agent 开发以及大模型 NL2Code 能力优化。

主要技术点：

- QueryAgent 模块：实现Query危害拒识、多轮对话 Query 改写、Query路由、实体抽取与对齐增强等功能。
- ChatAgent模块：基于 ReAct 架构，结合 LLM 的 Function Call 能力，实现拉取行内不同网站签退 Excel报表的RPA工具调用、邮件/短信配置与通知服务、定时查询设置服务等复杂 Tools 调用操作。
- 问数 Agent模块：基于 Code Interpreter，实现 NL2Code 问数分析 Agent，完成对查询类、统计类、模糊匹配类等8种类型问数查询分析，生成饼图、柱状图等可视化图表交互。
- 记忆模块：用户上下文对话历史记忆、任务状态记忆、获取的数据报表存储。

项目亮点与难点解决:

- QueryAgent优化：
  - **多轮对话 Query 改写**：针对多轮对话的意图补全和指代消解，通过构建完整与简略问题对训练数据（2～4轮对话 5k+），微调 Qwen2.5-7B，改写准确性达到 94%+。
  - Query 意图分类：针对多场景(3类)、多意图query(17种)， 训练 MacBERT 多标签分类，分类效果Micro-F1~0.96+。
  - **实体抽取与对齐增强**：微调 Qwen2.5-7B 实现业务实体词抽取，效果F1 95%。配置银行签退知识库，基于实体级召回排序对齐，增强简称、缩写和口语化处理，标准化 Query 表述。
- **ChatAgent优化**：针对7B模型API Call能力不稳定，设计loss-scale，基于通用/合成业务API两阶段混合微调强化ReAct交互轨迹。
- **问数 Agent 优化：**基于GPT-4合成Python业务代码，微调Deepseek-Coder/Qwen2.5-Coder，提升业务代码生成效果；完善错误信息、报错反问等数据集，DPO指导模型规范反馈。终版 Qwen2.5 32B 问数准确率达95.8%，PC、移动端均上线，测试优于闭源产品DataChat、略低于办公小浣熊。
- 部署优化：针对多模型显存占用大，基于vLLM动态加载多 LoRA 部署与 32B 量化优化。

项目成果：北京银行全行推广使用，100%覆盖到全国各分支行，平均节省 4 小时/人日以上，整体业务效率提升 50%+。

智能客服系统(知乎小管家) - 项目负责人（3人）

项目描述：知乎小管家旧版产品形态：用户 query→关键词匹配/意图识别→业务方确认及人工回复，流程过长且受限于人工确认与回复，导致超时、用户体验差；重点优化产品形态，引入自动回复等新功能，提升用户体验感。

工作职责：技术负责人，参与客服对话的产品形态改进，问题推荐、自动回复新功能设计；负责对话系统架构链路设计、QA库泛化拓展模块、文本匹配核心算法模块实现与优化工作。

主要技术点：系统基于 FAQ 采用召回+精排两阶段检索架构；具体基于ES与SBERT语义召回的多路召回，交互结构MonoBERT-RoBERTa(6L)为baseline的精排模型实现。

项目亮点与难点解决：

- 针对QA 库问答对泛化：负责深度聚类分析用户对话数据，探索实现生成式 Mengzi-T5 泛化相似 query，并引入决策模型判别机制筛选多轮式生成，效果评测人工校验生成准确率 87.5%，有效辅助审核人员快速扩充。

- 从数据与模型两方面优化排序效果：针对难例挖掘，基于 BM25 召回、边缘采样、EDA 增强与特定类型 case 挖掘等方式构建难负例训练集。基于 RBT6 对比尝试 MonoBERT、ConSERT 对比学习、CEDR 交互等模型结构，针对捕捉句对细微差异，提出基于大模型知识蒸馏的改进 CEDR 的多 MatchMatrix 深度交互模型解决方案。

项目成果：新对话服务上线评估误召率低至 0.16%，P 95%、R 81%，总体算法自动回复率达70%，折合节省约6人力/天。

知乎「悟空」反作弊系统内容类Spam挖掘识别 - 项目负责人（2人）

项目描述：随着知乎不断衍生的业务线，反作弊系统需扩展接入，但传统基于账号行为、IP设备等维度策略覆盖率低，而内容作弊是社区主要Spam类型尤其是导流信息、SEO特点的品牌内容，急需文本侧算法落地处理。

工作职责与技术点：项目主要负责人，负责参与内容类 Spam 识别系统搭建和算法研发；通过基于 RoBERTa(6L)-BiLSTM-CRF 的 baseline模型(实体抽取)+品牌词典匹配+导流正则模版匹配的混合框架实现。

项目亮点与难点解决：

- 针对新品牌、小众品牌等未登录新词识别：通过自由凝固度及左右邻字熵的新词发现+BERT任务领域预训练方案解决。
- **BERT领域预训练**：利用挖掘新词与知乎不同内容场景千万级自有业务数据 post-pretrain ZhiHu-RBT6，对比改进wwm掩蔽率15%、30%(F1 +2.3%)。作为基座模型后续也被应用到「内容时效性打标系统」、「不友善内容识别」等项目。
- 针对导流实体前缀与长 span 实体识别难点：研究并提出基于 BERT 深度表征与词性字形多特征融合架构的技术方案，对多样性特征利用 charCNN 和 MaxPooling 产出特征向量与 BERT Encoder 特征层拼接 attention 融合，多维度信息强化对带前缀类实体识别能力。对比引入 GlobalPointer 结构改进模型解码(F1 +1.6%)。

项目成果：评测最终效果 P 95.3%、F1 88.7%，在 4 个业务线部署上线，反作弊系统覆盖率提升 60%。

知乎问题路由智能化审核系统（从0-1）- 项目负责人（2人）

项目描述：知乎DAU不断增长，用户每天产生海量问题内容且含较多类型低质，社区治理业务面临人审后发策略的低审核效率、高人工成本的痛点，急需算法落地实现问题路由内容全自动化审核。

工作职责：负责与业务运营团队合作，参与制定标签标准；参与搭建知乎问题内容全自动化审核新系统。

主要技术点：审核算法模块链路设计、数据处理、训练集抽取与构建、模型研发评估及服务开发上线部署；基于word2vector-BiLSTM的baseline，探索研究BERT预训练模型的业务落地。

项目亮点与难点解决：

- 针对特定类型内容识别困难(文本多分类)，负责对比引入GRU结构，同时基于对抗训练、标签平滑等方式提升模型泛化。
- 针对标签类别多且不均衡问题，对比引入weighted CEloss、Focal Loss优化解决。
- 负责BERT推理性能优化，对比BERT-of-Theseus模型压缩、多模型ensemble蒸馏等解决方案，模型压缩(x0.5)、提速 (x1.84)、效果接近。终版效果优质P 97%，各类低质宏平均P 95.7%，总体宏平均F1 72.5%提升至84%。

项目成果：部署上线生产环境机审率达80%+，节省审核3~4人力/天。

教育经历

2016.08-2019.06　　中国科学院大学　　计算机技术　　硕士

- 《Handwritten character recognition algorithm based on multi-grained cascade multi-layered gradient boosting decision trees》（第一作者，CSCD、北大核心）

2012.08-2016.06　　青岛科技大学　　自动化　　本科

- 专业前15%，优秀学生，优秀毕业论文，6 次奖学金。

专业技能

1. **客服对话系统、知识图谱、大模型训练、Agent系统**等实际项目核心算法研发经验。
2. 掌握 Python，会用 Scala、SQL，了解 C++；熟悉 TensorFlow、PyTorch 框架。
3. 熟悉 Linux 系统及 Elasticsearch、Faiss、Milvus、Neo4j、Git、Vim、Docker常用工具；熟练使用LangGraph、AgentScope、Claude Agent SDK等Agent开发框架；熟悉使用Claude Code、Zcode等Vibe Coding工具。
4. 熟悉 XGBoost、K-Means、BM25、word2vector、TextCNN、LSTM、BERT、T5 等传统ML/DL/NLP算法。
5. 熟悉常用LLM的基础架构 LLaMA/Qwen/GLM 等，熟悉领域训练(CPT)、对齐训练(SFT, DPO,RLHF,GRPO,DAPO等)、部署(Quantization、vLLM)；熟练使用 LLaMaA-Factory、ms-swift、verl 开源训练框架。
6. 良好的英语读写的能力与数学基础，能独立阅读专业paper与技术复现，跟踪前沿学术动态。